

Inferencia y Estimación - TP 2 - Sintetización de fonemas mediante un modelo AR

Francisco Carruthers y Santiago L. Groba Alonso

Materia: Inferencia y Estimación

Grupo 03

Mayo 2025

Resumen

En este Trabajo Práctico se desarrolla un modelo autoregresivo (AR) para el análisis y la síntesis de nueve fonemas del habla (a, e, i, o, u, sh, f, s, j). Primero, se extraen tramos de 200 ms de señales reales y se evalúan su autocorrelación normalizada y su periodograma, comparándolos con la densidad espectral de potencia (PSD) teórica obtenida del modelo AR. Luego, se emplea el modelo ajustado para sintetizar versiones artificiales de cada fonema, concatenarlas en secuencias y evaluar auditivamente las diferencias entre vocales y fricativas, así como el efecto de la variación del pitch. Los resultados muestran un buen ajuste espectral entre las PSD empíricas y las teóricas, así como una fidelidad perceptiva razonable en la síntesis, aunque se observan limitaciones en la representación de componentes transitorios y formantes de alta frecuencia.

Índice

1. Introducción	2
2. Marco teórico	2
3. Desarrollo	3
3.1. Ejercicio 1: Análisis del modelo	3
3.2. Ejercicio 2: Síntesis de fonemas	6
4. Conclusiones	8

1. Introducción

Este trabajo aplica un modelo autoregresivo (AR) simple para analizar y sintetizar nueve fonemas del castellano. La idea es comprobar si, con unos pocos coeficientes y la fuente de excitación adecuada, podemos recrear el carácter espectral de cada sonido.

En el **Ejercicio 1** tomamos 200 ms de cada fonema real, estimamos un modelo AR, y comparamos su autocorrelación y PSD teórica con las medidas sobre la señal.

En el **Ejercicio 2**, a partir de los modelos obtenidos, generamos señales sintéticas excitando el filtro AR con trenes de pulsos o ruido blanco, y evaluamos subjetivamente la calidad de la síntesis y la influencia del pitch.

2. Marco teórico

El análisis y síntesis de fonemas se fundamenta en:

1. Periodograma (análisis no paramétrico) Para una señal real $x[n]$ de longitud N , el periodograma estimado es

$$\hat{S}_x(f_k) = \frac{1}{N} |\text{FFT}\{x[n]\}|^2, \quad f_k = \frac{k}{N} f_s, \quad k = 0, \dots, \frac{N}{2}.$$

Este estimador exhibe alta varianza para N finito, pero nos da la firma espectral empírica.

2. Modelo autoregresivo (AR) El habla se modela como la salida de un filtro IIR de orden P excitado por $u[n]$:

$$x[n] + \sum_{k=1}^P a_k x[n-k] = G u[n].$$

La PSD teórica resulta

$$S_x(f) = G^2 \frac{S_u(f)}{|1 + \sum_{k=1}^P a_k e^{-j2\pi f k / f_s}|^2}.$$

Estimamos $\{a_k\}$ por Yule-Walker en tramos de 200 ms y usamos `freqz(b, [1, -a1, ..., -aP], ..., fs)` para obtener $|H(e^{j\omega})|^2$.

3. Normalizaciones y ganancia Para poder comparar únicamente la forma espectral sin depender de las magnitudes absolutas, primero normalizamos cada tramo de señal a amplitud unitaria ($\max |x[n]| = 1$). A continuación, ajustamos la ganancia G de manera que el pico máximo de la PSD teórica coincida con el del periodograma empírico, asegurando así una alineación punto a punto de ambos espectros. Por último, restamos a cada

curva su valor máximo (0 dB) para superponerlas y resaltar únicamente sus variaciones en frecuencia.

4. Fuentes de excitación En la síntesis utilizamos dos tipos de excitación: para las vocales empleamos un tren de impulsos a la frecuencia fundamental f_0 , lo que genera líneas espectrales en $S_u(f)$; para las fricativas usamos ruido blanco, cuya densidad espectral es constante en todo el rango de frecuencia. De este modo reproducimos tanto la periodicidad de las vocales como la naturaleza arrítmica de las consonantes.

3. Desarrollo

3.1. Ejercicio 1: Análisis del modelo

Para cada fonema (a, e, i, o, u, sh, f, s, j) mostramos un panel 1×3 con (a) la señal de 200 ms normalizada, (b) su autocorrelación normalizada y (c) el periodograma empírico frente a la PSD teórica (ambas curvas normalizadas al mismo pico).




Figura 1: Fonema a: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 2: Fonema e: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 3: Fonema i: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 4: Fonema o: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 5: Fonema u: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 6: Fonema sh: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 7: Fonema f: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 8: Fonema s: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.




Figura 9: Fonema j: (a) señal 200 ms; (b) autocorrelación; (c) periodograma vs. PSD teórica.

A grandes rasgos, los paneles muestran que las **vocales** (a-u) presentan pulsos bien definidos; su autocorrelación revela un $F_0 \approx 200$ Hz con armónicos atenuados, y la PSD teórica reproduce con precisión los bajos (700–1200 Hz) y medios (2–4 kHz). Por contraste, las **fricativas** (sh, f, s, j) carecen de periodicidad: la autocorrelación cae casi a cero tras el retardo nulo y el periodograma muestra una banda ancha ruidosa. Aun así, la curva AR (naranja) sigue la envolvente general en todos los casos, lo que confirma que el modelo captura la distribución espectral aunque no describa los picos finos del ruido. Esto demuestra que, con muy pocos coeficientes, el modelo AR capta correctamente la firma espectral de cada fonema.

3.2. Ejercicio 2: Síntesis de fonemas

A partir de los coeficientes del modelo propuesto, se generaron versiones sintéticas de los nueve fonemas utilizando como excitación un tren de impulsos para las vocales y ruido blanco para las fricativas. Las señales se suavizaron en los bordes (20 % de la duración) y se normalizaron en amplitud. En la Figura 10 se observan los primeros 200 ms de cada fonema sintetizado, donde se distingue el patrón periódico de las vocales frente al carácter ruidoso de las consonantes fricativas.




Figura 10: Primeros 200 ms de los fonemas sintetizados por el modelo AR.

Para evaluar la calidad perceptiva, se concatenaron los fonemas obtenidos con un pitch fijo de 200 Hz en todas las vocales. La Figura 11 muestra la señal resultante, en la que las diferencias entre sonidos periódicos y ruidosos son claramente apreciables. Posteriormente, se sintetizó una secuencia adicional variando el pitch de cada vocal (a: 100 Hz, e: 125 Hz, i: 150 Hz, o: 125 Hz, u: 100 Hz), mientras que las fricativas se mantuvieron inalteradas. La señal correspondiente se ilustra en la Figura 12, donde se observa el cambio de tono en las vocales respecto al caso anterior.




Figura 11: Señal concatenada de los nueve fonemas sintetizados (pitch fijo de 200 Hz en vocales).




Figura 12: Señal concatenada de los nueve fonemas sintetizados, con variación de pitch en las vocales.

En todos los casos, la síntesis logró reproducir las características principales de cada fonema. Se destaca que, debido al suavizado y la normalización individual, la amplitud de los fonemas puede diferir en la señal concatenada. La percepción auditiva de las secuencias generadas refleja las diferencias básicas entre vocales y fricativas, aunque las señales resultantes presentan un carácter artificial y distan de la naturalidad de una grabación real.

4. Conclusiones

La síntesis de fonemas empleando modelos AR permitió generar señales con un comportamiento espectral y temporal coherente con el de los fonemas originales. Las diferencias entre vocales y fricativas se mantuvieron en la síntesis, así como el efecto de la variación de pitch en las vocales. El principal desafío estuvo en el ajuste del suavizado de bordes, que fue necesario para evitar artefactos pero puede reducir la energía efectiva de los fonemas. También se observaron diferencias de amplitud entre segmentos, atribuibles a la normalización individual y al suavizado aplicado. Aunque el modelo permite identificar los fonemas básicos, la calidad de la síntesis es claramente inferior a la de una señal real. Resultados más realistas requerirían modelos más complejos y una excitación mejor adaptada.

Referencias

- [1] M. Olmo y R. Nave, “Resonancia del Tracto Vocal,” *Hyperphysics*, 2023.
- [2] J. Makhoul, “Linear Prediction: A Tutorial Review,” *IEEE Proc.*, 1975.
- [3] P. Stoica y R. Moses, *Spectral Analysis of Signals*, 2005.